CQA · Conversation Quality Analytics

Оценка качества диалогов операторов с объяснением каждого балла

Прототип для Freedom Broker: чаты и звонки на RU, KZ и EN, настраиваемый чек-лист, апелляции и аналитика

Команда Data Mage · Freedom Data Challenge'26

Что получилось

1. **Оценка по чек-листу**
   Ответ, баллы, обоснование и реплика-доказательство по каждому критерию

2. **Чек-лист без кода**
   Новый критерий, замена или вес — в конструкторе, с версиями и переоценкой

3. **Апелляции**
   Аналитик оспаривает, проверяющий решает; оценка AI сохраняется

4. **Аналитика и звонки**
   Грубые ошибки в один клик, плеер записи с переходом к реплике

0.90 согласие с эталоном по критериям 01–08 на отложенных 28 диалогах

3.2 средняя ошибка итога, баллов из 100 (MAE)

$0.004 и около 8 секунд на диалог, 4 вызова модели

Модель классифицирует, баллы считает код

1. **Разбор**
   реплики m0…mN, время, удержания и паузы звонка
2. **Факты кодом**
   приветствие, задержка ответа, системные события
3. **Промпт**
   из активной версии чек-листа в БД
4. **LLM: ответ + цитата**
   строгая JSON-схема, 4 параллельных вызова
5. **Проверка**
   цитата есть в реплике, иначе 1 повтор; страховки
6. **Баллы кодом**
   N/A исключает вес, итог из 100

Новый критерий — сразу

Промпт и JSON-схема строятся из чек-листа: N/A только где разрешён, у шкалы — только её ступени.

Звонки как устная речь

Оговорки и ошибки распознавания не штрафуются, мягче порог сверки цитат, реплики консультации с коллегой — внутренние.

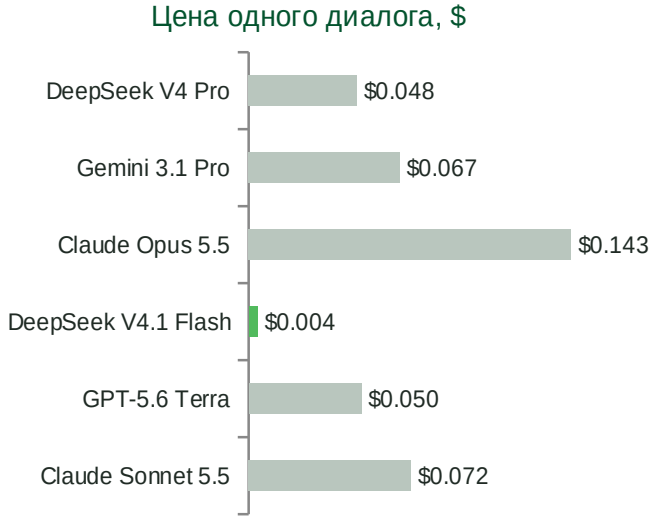
Персональные данные

Номера карт, ИИН, телефоны и коды маскируются до отправки в модель.

Шесть моделей: дороже не значит точнее

Модель	Доля совпадений	MAE, балл	Цена, $	Время, с
DeepSeek V4 Pro	0.92	3.7	0.048	53
Gemini 3.1 Pro	0.90	4.1	0.067	10
Claude Opus 5.5	0.89	6.2	0.143	12
DeepSeek V4.1 Flash	**0.89**	**3.5**	**0.004**	**8**
GPT-5.6 Terra	0.88	3.9	0.050	5
Claude Sonnet 5.5	0.88	7.7	0.072	9

Отложенные 28 диалогов, промпт p2, одинаковые настройки; цена и время — фактические из OpenRouter, на один диалог



Выбрали DeepSeek V4.1 Flash. Модели в 12–35 раз дороже дают +0.00–0.03 согласия и не уменьшают ошибку итога. Модель меняется одной настройкой, если компании важнее последние проценты.

Живое демо

1. Аналитика → грубые ошибки → карточка
2. Перейти к фрагменту и сырой ответ модели
3. Апелляция: аналитик → проверяющий
4. Чек-лист: вес и замена критерия → переоценка

github.com/Adilm8/Freedom-DataChallenge26