CQA · Conversation Quality Analytics

Оценка качества диалогов операторов с объяснением каждого балла

Прототип для Freedom Broker: чаты и звонки на RU, KZ и EN, настраиваемый чек-лист, апелляции и аналитика

Команда Data Mage · Freedom Data Challenge'26

Что получилось

1. **Оценка по чек-листу**
   Ответ, баллы, обоснование и реплика-доказательство по каждому критерию

2. **Чек-лист без кода**
   Новый критерий, замена или вес — в конструкторе, с версиями и переоценкой

3. **Апелляции**
   Аналитик оспаривает, проверяющий решает; оценка AI сохраняется

4. **Аналитика и звонки**
   Грубые ошибки в один клик, плеер записи с переходом к реплике

0.90 согласие с эталоном по критериям 01–08 на отложенных 28 диалогах

3.2 средняя ошибка итога, баллов из 100 (MAE)

$0.004 и около 8 секунд на диалог, 4 вызова модели

Модель классифицирует, баллы считает код

1. **Разбор**
   реплики m0…mN, время, удержания и паузы звонка
2. **Факты кодом**
   приветствие, задержка ответа, системные события
3. **Промпт**
   из активной версии чек-листа в БД
4. **LLM: ответ + цитата**
   строгая JSON-схема, 4 параллельных вызова
5. **Проверка**
   цитата есть в реплике, иначе 1 повтор; страховки
6. **Баллы кодом**
   N/A исключает вес, итог из 100

Новый критерий — сразу

Промпт и JSON-схема строятся из чек-листа: N/A только где разрешён, у шкалы — только её ступени.

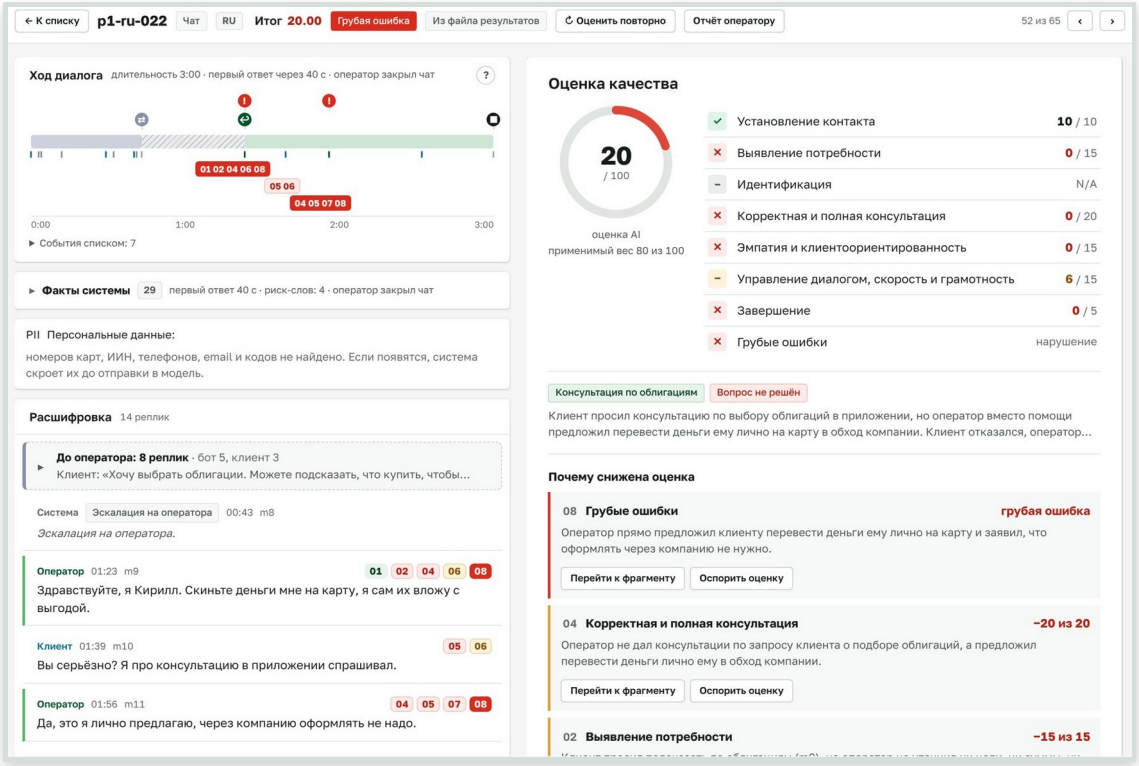
Звонки как устная речь

Оговорки и ошибки распознавания не штрафуются, мягче порог сверки цитат, реплики консультации с коллегой — внутренние.

Персональные данные

Номера карт, ИИН, телефоны и коды маскируются до отправки в модель.

Карточка: балл, обоснование, доказательство



1 Почему снижена оценка

Каждый потерянный балл с причиной и кнопками «Перейти к фрагменту» и «Оспорить»

2 Метки на репликах

Видно, на какую реплику ссылается каждый критерий

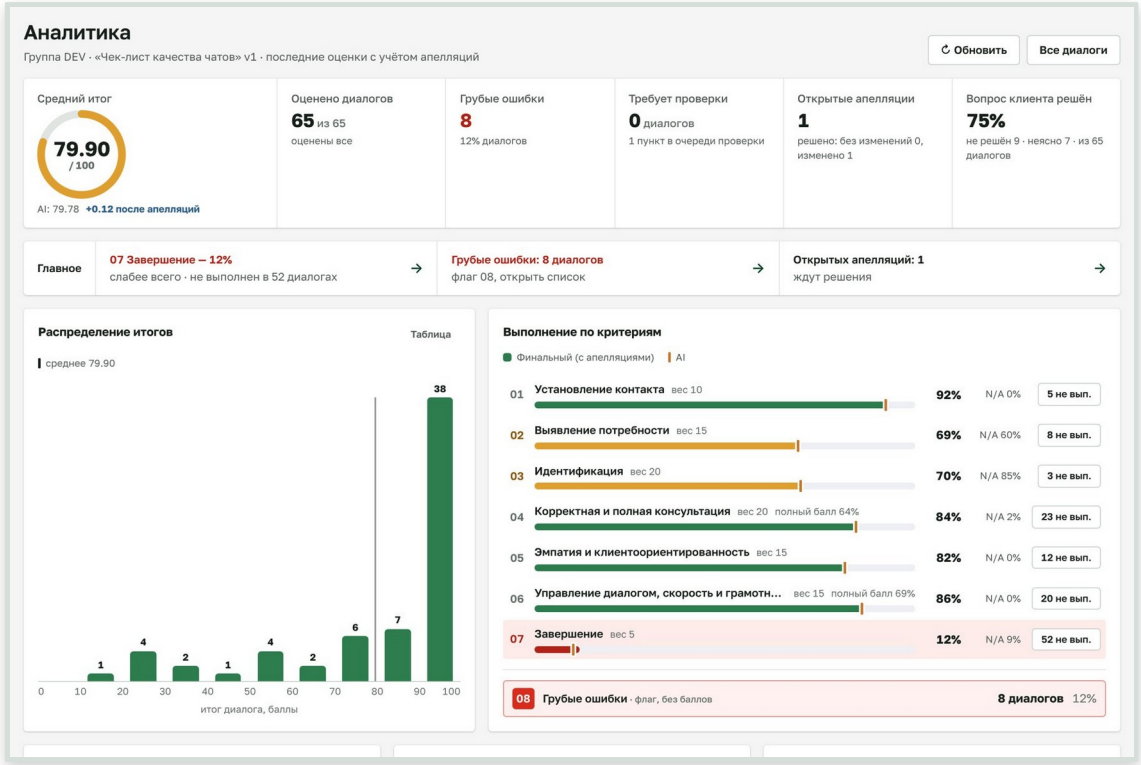
3 Ход диалога

Бот, эскалация, первый ответ оператора, подтверждение личности

4 Честность

Модель, токены, цена и сырой ответ каждого вызова

Аналитика для руководителя качества



1. **Главное сверху**

   Слабейший критерий, грубые ошибки и открытые апелляции

2. **Клик — список**

   Любая цифра или полоса открывает диалоги с этим фильтром

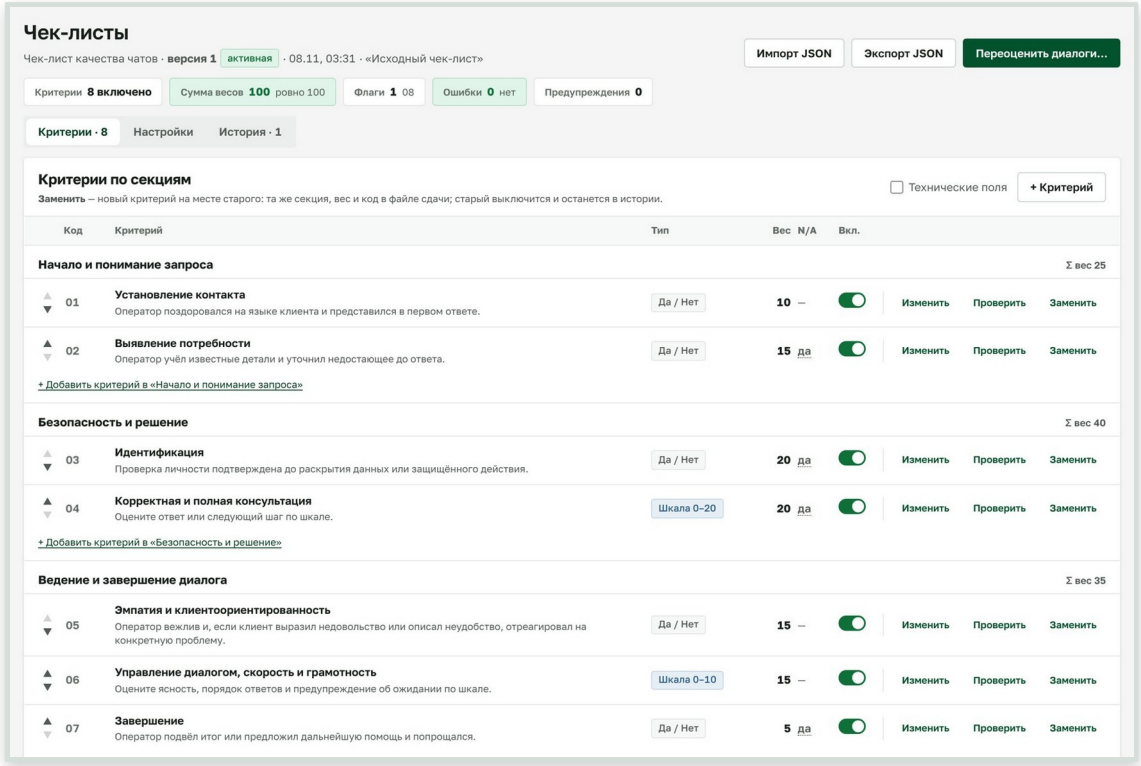
3. **AI и финальный**

   Итоги до и после апелляций

4. **Требует проверки**

   Где модели не хватило уверенности или данных

Чек-лист меняется без кода



1 Вес

Итоги пересчитываются кодом, без вызовов модели

2 Новый критерий

Один вызов на диалог, остальные ответы переиспользуются

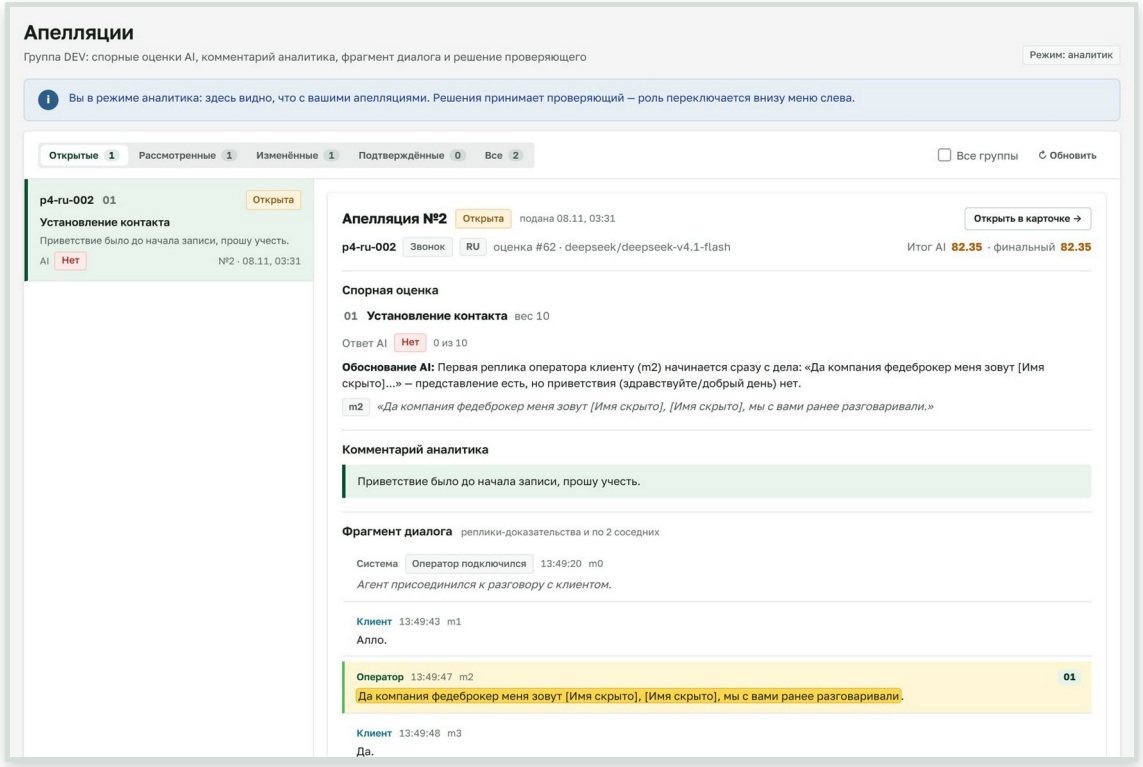
3 Заменить в один шаг

Та же секция, вес и код в файле сдачи; версии неизменяемы

4 Черновик с ИИ

Критерий по описанию; «Проверить» — проба на диалоге до сохранения

Апелляция не затирает оценку AI



1 Аналитик

«Оспорить оценку» у критерия с комментарием

2 Проверяющий

Видит обоснование AI, комментарий и фрагмент, подтверждает или меняет

3 Три слоя

Ответ AI → решение с причиной → финальный итог

4 Второе мнение ИИ

Вслепую переоценивает спорный критерий одним вызовом

Точность против эталона

0.90

согласие по критериям, отложенные 28 (95% ДИ 0.86–0.93)

3.2

MAE итога, баллов (2.6–6.5)

1.0

recall и precision флага грубой ошибки

Выборка	Согласие 01–08	MAE итога
Отложенная, 28 диалогов	0.90	3.2
Разработка, 37 диалогов	0.89	5.3
Проверенные вручную, 30	0.84	7.1

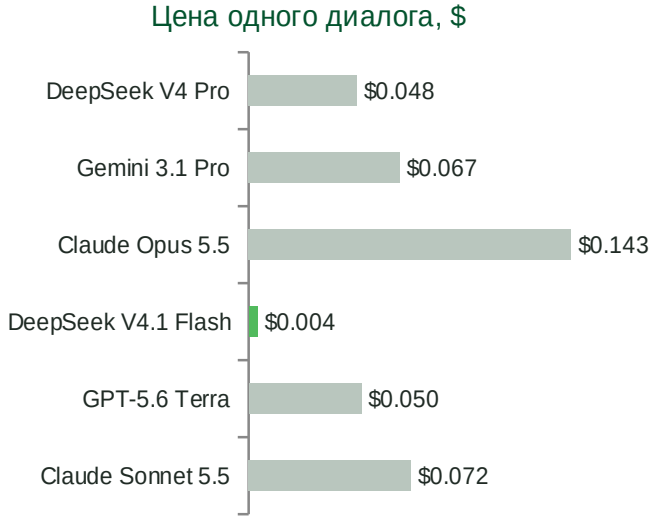
Как мерили

- Своя разметка всех 65 диалогов DEV; 30 проверены человеком
- Разбиение зафиксировано до прогонов, промпт правили только по dev
- В промпте нет примеров из DEV
- Разброс одинаковых прогонов — до ±1.5 MAE

Шесть моделей: дороже не значит точнее

Модель	Согласие	MAE	$ / диалог	с / диалог
DeepSeek V4 Pro	0.92	3.7	0.048	53
Gemini 3.1 Pro	0.90	4.1	0.067	10
Claude Opus 5.5	0.89	6.2	0.143	12
DeepSeek V4.1 Flash	**0.89**	**3.5**	**0.004**	**8**
GPT-5.6 Terra	0.88	3.9	0.050	5
Claude Sonnet 5.5	0.88	7.7	0.072	9

Отложенные 28 диалогов, промпт p2, одинаковые настройки; цена и время — фактические из OpenRouter



Выбрали DeepSeek V4.1 Flash. Модели в 12–35 раз дороже дают +0.00–0.03 согласия и не уменьшают ошибку итога. Модель меняется одной настройкой, если компании важнее последние проценты.

Реальный анализ, а не заготовки

1

Каждая оценка — вызов LLM

В БД: провайдер, модель, версии промпта и чек-листа, токены, цена, время, полный промпт и сырой ответ

2

Цитаты проверяются

Выдуманная цитата или номер реплики — повтор с перечнем ошибок, затем «требует проверки»

3

Не додумывает

Нет данных — низкая уверенность и очередь проверки, N/A — с причиной

4

Воспроизводимо

results.json в формате организаторов с проверкой, 255 автотестов, скрипт контрольного прогона

Сильные стороны и ограничения

Сильные стороны

- Точность на уровне сильных моделей при цене $0.004 за диалог
- Каждый балл объяснён и привязан к реплике
- Чек-лист меняется без кода, правка стоит 0–1 вызов на диалог
- Апелляции с сохранением оценки AI и вторым мнением
- Звонки с плеером, интерфейс RU / EN / KZ

Ограничения

- Эталон — наша разметка, методику организаторов не угадывали
- Шкалы 04 и 06 — главные расхождения с эталоном
- Основной путь — облачная модель; локальная подключается тем же интерфейсом, но не замерена
- Нет своей транскрибации: интонацию и темп не оцениваем
- Прототип: SQLite, без входа и деплоя (не требовались)

Живое демо

1. Аналитика → грубые ошибки → карточка
2. Перейти к фрагменту и сырой ответ модели
3. Апелляция: аналитик → проверяющий
4. Чек-лист: вес и замена критерия → переоценка

github.com/Adilm8/Freedom-DataChallenge26